

1. 假定用于分析的数据包含属性 age, 数据元组中 age 的值如下:

[22, 36, 25, 70, 19, 20, 33, 45, 16, 25, 20, 15, 35, 21, 30, 33, 25, 40, 22, 16, 13, 35, 35, 52, 33, 46, 35, 25]. 分别按照等宽和等频的方法将上述数据划分到 4 个不同区间内。需要给出区间的划分方式, 以及每个区间包含数组中的哪些数据。

1. 首先将数据排序: [13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25, 25, 30, 33, 33, 33, 35, 35, 35, 35, 36, 40, 45, 46, 52, 70]

a) 等宽法划分:

数据范围为 $70 - 13 = 57$, 区间宽度为 $\frac{57}{4} = 14.25$

故区间 1 [13, 27.25), 包含数据: [13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25, 25]

区间 2 [27.25, 41.5), 包含数据: [30, 33, 33, 33, 35, 35, 35, 35, 36, 40]

区间 3 [41.5, 55.75), 包含数据: [45, 46, 52]

区间 4 [55.75, 70), 包含数据: [70]

b) 等频法, 每个区间数据量为 $\frac{28}{4} = 7$

区间 1 (1~7), 包含数据 [13, 15, 16, 16, 19, 20, 20]

区间 2 (8~14) 包含 [21, 22, 22, 25, 25, 25, 25]

区间 3 (15~21) [30, 33, 33, 33, 35, 35, 35]

区间 4 (22~28) [35, 36, 40, 45, 46, 52, 70]

2. 假设你有以下数据集, 表示某个班级学生的数学成绩 (单位: 分): [60, 70, 80, 90, 100], 请对该数据集进行标准化处理。

2. 均值 $\mu = (60 + 70 + 80 + 90 + 100) \div 5 = 80$

标准差 $\sigma^2 = \frac{(60-80)^2 + (70-80)^2 + (80-80)^2 + (90-80)^2 + (100-80)^2}{5} = 200$

标准差 $\sigma = \sqrt{200} \approx 14.14$

则标准化结果分别为 $\frac{60-80}{14.14} = -1.41$, $\frac{70-80}{14.14} = -0.71$, $\frac{80-80}{14.14} = 0$

$\frac{90-80}{14.14} = 0.71$, $\frac{100-80}{14.14} = 1.41$

标准化处理后的数据集: [-1.41, -0.71, 0, 0.71, 1.41]

3. 对于下面的向量 x 和 y , 计算指定的相似性或距离度量。

(a) $x=(1, 1, 1, 1)$, $y=(2, 2, 2, 2)$, 计算余弦、皮尔森相关系数、欧几里得。

(b) $x=(0, 1, 0, 1)$, $y=(1, 0, 1, 0)$, 计算余弦、皮尔森相关系数、欧几里得。

(c) $x=0101010001$, $y=0100011000$, 计算两个二元向量之间的简单匹配系数和 Jaccard 相似度。

3. (a) ①余弦相似度: $\cos = \frac{\vec{x} \cdot \vec{y}}{\|\vec{x}\| \cdot \|\vec{y}\|} = \frac{1 \times 2 + 1 \times 2 + 1 \times 2 + 1 \times 2}{\sqrt{1^2+1^2+1^2+1^2} \cdot \sqrt{2^2+2^2+2^2+2^2}} = \frac{8}{2 \times 4} = 1$

②皮尔森相关系数: 因 x, y 均为常数向量, 方差为 0, 标准差为 0, 分母为 0, 故未定义, 或者说无相关性

③欧几里得距离: $Dist = \sqrt{(1-2)^2 + (1-2)^2 + (1-2)^2 + (1-2)^2} = 2$

(b) 余弦: 由 $\vec{x} \cdot \vec{y} = 0 + 0 + 0 + 0 = 0$, 故 $\cos = \frac{0}{\|\vec{x}\| \cdot \|\vec{y}\|} = 0$

②皮尔森相关: $\bar{x} = 0.5, \bar{y} = 0.5, \text{Cov}(x, y) = [(-0.5)(0.5) + (0.5)(-0.5) + (-0.5)(0.5) + (0.5)(-0.5)]/4 = -0.15$

$\sigma_x = 0.5, \sigma_y = 0.5, \text{Corr} = \frac{-0.15}{0.5 \times 0.5} = -1$, 完全负相关

③欧几里得距离: $Dist = \sqrt{(0-1)^2 + (1-0)^2 + (0-1)^2 + (1-0)^2} = \sqrt{4} = 2$

(c) $x=0101010001$
 $y=0100011000$

$$\Rightarrow$$

	$y=1$	$y=0$
$x=1$	$M_{11}=2$	$M_{10}=2$
$x=0$	$M_{01}=1$	$M_{00}=5$

简单匹配系数: $\frac{M_{11} + M_{00}}{\text{Total}} = \frac{2+5}{10} = 0.7$

Jaccard 相似度: $\frac{M_{11}}{M_{11} + M_{01} + M_{10}} = \frac{2}{2+2+1} = \frac{2}{5} = 0.4$

4. 考虑如下二分类问题的训练样本集

(a) 整个训练样本集关于类属性的熵是多少?

(b) 关于这些训练样本, a_1 和 a_2 的信息增益是多少?

(c) 对于连续属性 a_3 , 计算所有可能的划分的信息增益。

(d) 根据信息增益, 哪个是最佳划分(在 a_1 、 a_2 和 a_3 中)?

(e) 根据分类误差, 哪个是最佳划分(在 a_1 和 a_2 中)?

(f) 根据基尼指数, 哪个是最佳划分(在 a_1 和 a_2 中)?

实例	a_1	a_2	a_3	类标号
1	T	T	1.0	+
2	T	T	6.0	+
3	T	F	5.0	-
4	F	F	4.0	+
5	F	T	7.0	-
6	F	T	3.0	-
7	F	F	8.0	-
8	T	F	7.0	+
9	F	T	5.0	-

4. 由表得知, 总样本 $N=9$, 类别1分布: + 4个, - 5个

$$(a) \text{ 整体熵 } E(S) = -\frac{4}{9} \log_2 \left(\frac{4}{9} \right) - \frac{5}{9} \log_2 \left(\frac{5}{9} \right) \\ \approx 0.520 + 0.471 = 0.991$$

(b) $a_1 = T$ (实例: 1, 2, 3, 8): 类标号 {+, +, -, +}

$$\text{则 } E(a_1 = T) = -0.75 \log_2 (0.75) - 0.25 \log_2 (0.25) \approx 0.918$$

$a_2 = F$ (实例: 4, 5, 6, 7, 9), 类标号 {+, -, -, -, -}

$$E(a_2 = F) = -0.2 \log_2 (0.2) - 0.8 \log_2 (0.8) \approx 0.722$$

$$\text{增益 } \text{Gain}(a_1) = 0.991 - \left[\frac{4}{9} \times 0.918 + \frac{5}{9} \times 0.722 \right] = 0.991 - (0.360 + 0.401) = 0.230$$

② a_2 :

$a_2 = T$ (实例: 1, 2, 5, 6, 9), 类标号 {+, +, -, -, -}

$$E(a_2 = T) = -0.4 \log_2 (0.4) - 0.6 \log_2 (0.6) \approx 0.971$$

$a_2 = F$ (实例: 3, 4, 7, 8), 类标号 {-, +, -, +}

$$E(a_2 = F) = -0.5 \log_2 (0.5) - 0.5 \log_2 (0.5) = 1.0$$

$$\text{则 } a_2 \text{ 信息增益 } \text{Gain}(a_2) = 0.991 - \left[\frac{5}{9} \times 0.971 + \frac{4}{9} \times 1.0 \right] = 0.008$$

(C) 对于 a_3 , 排序后的 (值, 类别): (1, +), (3, -), (4, +), (5, -), (5, -), (6, +), (7, -), (11, +), (18, -)

主要那被切分点

① 2.0: 左边 (+), 右边 (3, -) $G_{ain} = 0$

$$E(a_3 < 2.0) = 0, E(a_3 > 2.0) = -0.375 \log(0.375) - 0.625 \log(0.625) = 0.53 + 0.424 \approx 0.955$$

$$G_{ain}(a_3) = 0.991 - (\frac{1}{9} \times 0 + \frac{8}{9} \times 0.955) = 0.142$$

② 切 3.5, 左 (1, +), 右 (3, -). 同理得 $G_{ain}(a_2) \approx 0.003$

③ 切 4.5, 左 (2, +), 右 (2, -), $G_{ain} \approx 0.073$

④ 切 7.5, 左 (4, +), 右 (1, -). $G_{ain} \approx 0.103$

故各划分中最佳点是 2.0, 增益约为 0.142

⑤ $0.230 < 0.142 > 0.008$, 故最佳划分是 a_1

(e) 父节点误差 $Err_H(P) = \frac{4}{9} \approx 0.44$

a_1 划分: T 节点 (3, +), 预测 +, 错 1

F 节点 (1, -), 预测 -, 错 1

加权误差 $\frac{1}{9} \approx 0.22$

a_2 划分: T 节点 (2, +), 预测 +, 错 2

F 节点 (2, -), 随机预测, 错 2

加权误差 $\frac{2}{9} \approx 0.44$

故最佳划分是 a_1

(f) 基尼系数

$$a_1 \text{ 划分: } Gini(T) = 1 - [\left(\frac{3}{9}\right)^2 + \left(\frac{1}{9}\right)^2] = 0.375$$

$$Gini(F) = 1 - [\left(\frac{1}{9}\right)^2 + \left(\frac{8}{9}\right)^2] = 0.320$$

$$Gini_{split}(a_1) = \frac{4}{9} \times 0.375 + \frac{5}{9} \times 0.320 = 0.344$$

$$a_2: Gini(T) = 1 - [\left(\frac{2}{9}\right)^2 + \left(\frac{2}{9}\right)^2] = 0.480$$

$$Gini(F) = 1 - [\left(\frac{2}{9}\right)^2 + \left(\frac{6}{9}\right)^2] = 0.5$$

$$Gini(a_2) = \frac{5}{9} \times 0.480 + \frac{4}{9} \times 0.5 = 0.489$$

$0.344 < 0.489$, 根据基尼系数最佳划分是 a_1

5. 考虑下表中的一维数据集。

(a) 根据 1-最近邻、3-最近邻、5-最近邻及 9-最近邻，对数据点 $x=5.0$ 分类(使用多数表决)。

(b) 根据距离权衡每个最近邻 x_i 的影响 $w_i = \frac{1}{|x_i - x|}$ ，使用距离加权表决方法重复前面的分析。

x	0.5	3.0	4.5	4.6	4.9	5.2	5.3	5.5	7.0	9.5
y	-	-	+	+	+	-	-	+	-	-

5. (a) 由表中数据，

① 1-最近邻是 4.9, $y=+$, 分类结果为 +

② 3-最近邻, 邻居为 $x = \{4.9, 5.2, 5.3\}$, 其中 1 个 +, 2 个 -, 分类结果为 -

③ 5-最近邻, 邻居为 $x = \{4.9, 5.2, 5.3, 4.6, 4.5\}$ 其中 3 个 +, 2 个 -, 分类结果为 +

④ 9-最近邻, 邻居为除 0.5 和 9.5 外的所有点, 由于 $x=0.5$ 或 9.5 时 y 都为 -, 故包含 4 个 +, 5 个 -, 分类结果为 +

(b) ① 1-最近邻, 仅有 (4.9, +), 结果显然为 +

② 3-最近邻, + 的权重为 $\frac{1}{|4.9-5|} = 10$, - 的权重 $\frac{1}{|5.2-5|} + \frac{1}{|5.3-5|} \approx 8.33$
 $10 > 8.33$, 结果为 +

③ 5-最近邻, + 权重: $10 + \frac{1}{|4.6-5|} + \frac{1}{|4.5-5|} = 10 + 2.5 + 2 = 14.5$
 - 权重 8.33, $14.5 > 8.33$, 结果为 +

④ 9-最近邻: + 权重 $14.5 + \frac{1}{|5.5-5|} = 16.5$, - 权重 $8.33 + \frac{1}{|3.0-5|} + \frac{1}{|7.0-5|} + \frac{1}{|9.5-5|} \approx 9.55$
 $16.5 > 9.55$, 结果为 +