

1. 下表的数据集包含两个属性 X 和 Y，两个类标签 “+” 和 “-”。每个属性取 3 个不同的值：0，1 或 2。

X	Y	实例数	
		+	-
0	0	0	100
1	0	0	0
2	0	0	100
0	1	10	100
1	1	10	0
2	1	10	100
0	2	0	100
1	2	0	0
2	2	0	100

- (a) 使用分类误差建立该数据集的决策树。
(b) 决策树的准确率、精度、召回率和 F1 度量各是多少?(注意，精度、召回率和 F1 度量均是对 “+” 类定义的。)要给出混淆矩阵和具体的计算过程。

2. 考虑下表中的数据集

- (a)估计条件概率 $P(A|+)$ 、 $P(B|+)$ 、 $P(C|+)$ 、 $P(A|-)$ 、 $P(B|-)$ 和 $P(C|-)$ 。
(b)根据(a)中的条件概率，使用朴素贝叶斯方法预测测试样本($A=0$, $B=1$, $C=0$)的类标签。

样本	A	B	C	类标号
1	0	0	0	+
2	0	0	1	-
3	0	1	1	-
4	0	1	1	-
5	0	0	1	+
6	1	0	1	+
7	1	0	1	-
8	1	0	1	-
9	1	1	1	+
10	1	0	1	+

3. 某产品的广告费支出 x (单位:百万元) 与销售额 y (单位: 百万元)之间有如下数据:

- (1)使用最小二乘法求 y 关于 x 的线性回归方程。需要给出具体的计算过程。
(2)预测广告费为 9 百万元时的销售额是多少。

x	2	4	5	6	8
y	30	40	60	50	70

4. 设有如下所示交易数据库:

TID	购买商品
T1	{a,b}
T2	{b,c,d}
T3	{c}
T4	{b,d}

- (1) 令 $\min_sup = 0.5$, 试用 Apriori 算法求出其所有的频繁项集。需要给出具体过程。
- (2) 令 $\min_conf = 0.7$, 在所得频繁项集的基础上, 求出所有的强关联规则。
- (3) 为每一条强关联规则, 绘制出对应的列联表, 并计算对应的提升度。

5. 一维点的集合是:{6, 12, 18, 24, 30, 42, 48}, 执行 K 均值算法

(a)对于下列每组初始质心, 将每个点指派到最近的质心, 创建两个簇, 然后对两个簇的每组质心分别计算总平方误差。对每组质心, 给出这两个簇和总平方误差

i.(18, 45)

ii.(15, 40)

(b)两组质心代表稳定解吗, 即如果在该数据集上, 使用给定的质心作为初始质心运行 K 均值, 所产生的簇会有改变吗?