



数据挖掘

Data Mining

主讲: 张仲楠 教授



廈門大學
XIAMEN UNIVERSITY



绪论

目 录

01

数据时代

02

数据挖掘概念

03

数据挖掘的起源

04


数据挖掘任务

05

数据挖掘要解决的问题

1. 数据时代

一分钟能做什么？



微信用户每一分钟发布**46.52万**张图片；每一分钟发起**22.91万**次视频通话；每一分钟会有**54.16万**人进入朋友圈。



百度用户每一分钟进行**416.6万**次搜索。每一分钟有**6.94万**次语音播报。



抖音海外版 TikTok 用户一分钟观看了 **1.67 亿**条视频




淘宝每一分钟会有658.8万人民币销售额。天猫每分钟会有767.59万销售额。




B站每分钟会有**83.3万**次播放。

1. 数据时代

一分钟能做什么？




2021年互联网用户总数为50亿，比2020年的45亿增长了大约增长了5亿，也就是每一分钟增加**950名**新用户。



1. 数据时代


交通数据



物联网数据



医学数据




天文观测数据



生命科学数据



地球观测数据



1. 数据时代

数据挖掘发展的动力

- 数据爆炸：数据**采集工具**和成熟的数据**存储技术**使得大量的数据被收集和存储
- 我们拥有**丰富的数据**，但是**缺乏有用的信息**
- 迫切需要将**传统的数据分析方法**与用于处理大量数据的**复杂算法**相结合

1. 数据时代



2023年10月25日，国家数据局正式揭牌。

《“数据要素×”三年行动计划(2024-2026年)》总览



1. 数据时代

数据挖掘的价值 --- 电子商务领域



- 1. 个性化推荐系统：通过分析用户的**历史购买记录**和**行为习惯**，为用户提供**个性化的产品推荐**，提高购物体验和销售额。
- 2. 交易风险评估：基于大量的**历史交易数据**，通过数据挖掘的方法分析交易模式，提前识别**潜在的诈骗和欺诈行为**。
- 3. 市场细分：将用户数据进行分析，识别不同的**市场细分**，制定相应的销售和营销策略，提高销售效率。
- 4. 购物篮分析：分析不同产品之间的**关联关系**，为电商平台提供交叉销售的机会，提高销售额。

1. 数据时代

数据挖掘的价值 --- 金融领域



- 1. 信用评估：通过分析个人或企业的**历史信用信息**和各类数据，进行**信用评估**，帮助金融机构决策。
- 2. 欺诈检测：通过对交易数据进行分析，发现潜在的欺诈模式和异常行为，**预防金融欺诈**事件的发生。
- 3. 股市预测：通过对**历史股票数据进行挖掘**，建立股市**预测模型**，辅助投资者做出投资决策。
- 4. 风险管理：通过对大规模的金融数据进行挖掘，分析不同风险因素对投资组合的影响，提供风险管理策略。

1. 数据时代



数据挖掘的价值 --- 医疗健康领域

- 1. 疾病预测：基于患者的**个人信息和病历数据**，预测患者可能患上某些**疾病的概率**，提前进行干预和治疗。
- 2. 药物研发：通过对已有研究和**药物数据**进行分析，挖掘**新的药物治疗方案**和疗效评估方法。
- 3. 医疗资源优化：通过对**医疗数据进行挖掘**，医院可以更好地管理和调整资源，**提高医疗服务的效率和质量**。
- 4. 健康风险评估：基于个人健康数据和生活习惯，评估个体的健康风险，并提供相应的健康管理建议。

1. 数据时代

数据挖掘的价值 --- 交通运输领域



- 1. 智能交通调度：通过分析**交通流量数据**和**道路网络信息**，**优化交通调度**和信号灯配时，减少交通拥堵和延误。
- 2. 交通事故预测：通过对历史交通事故数据和天气数据进行挖掘，建立**交通事故预测模型**，预防和减少交通事故发生。
- 3. 公共交通优化：通过分析公共交通数据和乘客出行模式，**优化公共交通线路和班次**，提高乘客出行效率。

1. 数据时代



数据挖掘的价值 --- 社交媒体领域

- 1. 用户情感分析：通过分析用户在社交媒体上的**发帖内容**和**情感表达**了解用户对不同话题和事件的**态度和情感倾向**。
- 2. 舆情监测：通过对社交媒体上的数据进行挖掘，了解公众对某一事件或话题的**态度和舆论趋势**。
- 3. 社交关系分析：通过分析社交媒体上的用户行为和互动，了解用户之间的**社交关系**和**用户群体特征**。

1. 数据时代



数据挖掘的价值 --- 制造业领域

- 1. 产品质量控制：通过分析制造过程中的**传感器数据**和**生产参数**，实时**监控产品质量**，提前发现和预防质量问题。
- 2. 故障预测与预防：通过对设备故障数据和维修记录进行挖掘，**预测设备故障的概率和时间**，提前进行维修和保养，减少生产中断时间。
- 3. 供应链优化：通过分析供应链上的数据，了解供应链网络、库存和物流的状态，**优化供应链的运作效率**。

1. 数据时代

数据挖掘的价值 --- 教育领域


- 1. 学生表现预测：通过分析学生的个人信息和学习行为数据，预测学生未来的学习成绩和表现，**提供个性化教育方案。**
- 2. 学习模式分析：通过对学生的学习行为和学习轨迹数据进行挖掘了解不同学生的学习模式和学习风格，辅助教师做出**个性化的教学决策。**



1. 数据时代

数据挖掘的价值 --- 政府与公共服务领域

- 1. 犯罪预测：通过分析犯罪历史数据和环境因素，**预测不同区域的犯罪概率和类型**，提前采取措施维护社会治安。
- 2. 政府支出分析：通过分析政府财政数据和项目投资数据，**优化政府支出结构和预算分配**，提高投资效益。
- 3. 疫情预测与控制：通过对传染病数据和人口流动数据进行挖掘，**预测疫情的传播趋势和高风险区域**，制定相应的疫情防控策略。



1. 数据时代

数据挖掘的价值 --- 农业领域

- 1. 作物病虫害预警：通过分析农作物生长环境数据和病虫害历史数据提前预警并采取防控措施，保护作物产量。
- 2. 农产品价格预测：通过对市场供需数据和经济因素的分析，预测农产品价格水平和趋势，为农民和市场参与者提供参考依据。



目 录

01

数据时代

02

数据挖掘概念

03

数据挖掘的起源

04

数据挖掘任务

05

数据挖掘要解决的问题

2. 数据挖掘概念


什么是数据挖掘



数据挖掘(Data Mining)是从**大量数据**中自动提取**有价值的模式、知识或信息**的过程，通常涉及统计分析、机器学习和数据库技术。它用于发现**隐藏的关系、趋势或规律**，以**支持决策和预测**。




数据挖掘是从**大量数据**中提取出**有价值信息**的过程，涉及统计分析、机器学习和数据库技术，旨在发现**隐藏的模式、趋势和关联**，以**支持决策制定**。



2. 数据挖掘概念

什么是数据挖掘

- 数据挖掘是在大型数据库中自动发现有用信息的过程
 - 探查大型数据库
 - 发现先前未知的有用模式 (pattern)
- 可以预测未来的观测结果
- 并非所有的信息发现任务都被视为数据挖掘
 - 数据库的查询任务




2. 数据挖掘概念

什么是数据挖掘

- 数据挖掘是数据库中知识发现 (KDD) 不可缺少的一部分
- KDD是识别数据中有效的、新颖的、潜在有用的和易于理解的模式的非平凡过程(Goebel, 1999)

KDD
过程




2. 数据挖掘概念

什么是数据挖掘

- 预处理是将原始输入数据转换为适当的格式，以便后续分析
 - 融合多个数据源的数据，数据清洗（消除噪声和重复值），选择与任务相关的记录和特征

KDD
过程




2. 数据挖掘概念



什么是数据挖掘

- 后处理确保只将有效和有用的结果集成到决策支持系统(DSS)中
 - 可视化: 使得数据分析者从不同的视角探查数据和挖掘结果
 - 使用统计度量或假设检验, 删除虚假挖掘结果

KDD
过程



目 录

01

数据时代

02

数据挖掘概念

03

数据挖掘的起源

04


数据挖掘任务

05

数据挖掘要解决的问题

3. 数据挖掘的起源

1989年8月于美国底特律市召开的第十一届国际联合人工智能学术会议上首次提到“**知识发现**”这一概念；



到1993年，美国电气电子工程师学会(IEEE)的知识与数据工程(Knowledge and Data Engineering)汇刊出版了**KDD**技术专刊，发表的论文和摘要体现了当时KDD的最新研究成果和动态。




1995年在加拿大蒙特利尔召开的首届“知识发现和数据挖掘”国际学术会议上，首次提出了“**数据挖掘**”这一学科的名称，并把数据挖掘技术分为科研领域的知识发现与工程领域的数据挖掘。



3. 数据挖掘的起源

多学科交叉

- 涉及数据库技术、人工智能、数理统计、机器学习、模式识别、高性能计算、知识工程、神经网络、信息检索、信息的可视化等众多领域



目 录

01

数据时代

02

数据挖掘概念

03

数据挖掘的起源

04

数据挖掘任务


05

数据挖掘要解决的问题


4. 数据挖掘的任务

数据挖掘要做什么

- 数据挖掘的两大基本任务是**预测**和**描述**
- 预测任务：根据其他属性的值**预测特定属性的值**
 - 被预测的属性：目标变量/因变量
 - 用于预测的属性：解释变量/自变量
- 描述任务：导出数据中潜在联系的模式
 - 相关、趋势、聚类、轨迹和异常
 - 探查性的，需要加以验证和解释



4. 数据挖掘的任务




聚类分析

数据

ID	有房	婚姻状况	年收入	拖欠贷款
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes


预测建模



关联分析



异常检测



4. 数据挖掘的任务

1. 预测建模

■ 为目标变量建立模型，将其作为解释变量的函数

■ 分类：用于预测离散(比如: Yes/No)的目标变量


■ 回归：用于预测连续(比如: 0.57)的目标变量

■ 任务目标：使目标变量的预测值与实际值之间的误差最小




分类

有房	婚姻状况	年收入	拖欠贷款
No	Married	80K	???



4. 数据挖掘的任务

房子面积	占地大小	卧室	花岗岩	卫生间重装	销售价格
3529	9191	6	0	0	205, 000
3247	10061	5	1	1	224, 900
4032	10150	5	0	1	197, 900
2397	14156	4	1	0	189, 900
2200	9600	4	0	1	195, 000
3536	19994	6	1	1	325, 000
2983	9351	5	0	1	230, 000
3198	9669	5	1	1	????



???? ← 219, 358

回 归

4. 数据挖掘的任务

2. 关联分析

- 用来发现描述数据中**强关联**特征的模式
 - 所发现的模式通常用**蕴含规则**或**特征子集**的形式表示变量
- 任务目标：以**最有效**的方式提取**最有趣**的模式

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke




$\{Milk, Diaper\} \rightarrow \{Beer\}$
 $\{Milk, Beer\} \rightarrow \{Diaper\}$
 $\{Diaper, Beer\} \rightarrow \{Milk\}$
 $\{Beer\} \rightarrow \{Milk, Diaper\}$

} 规则

4. 数据挖掘的任务

3. 聚类分析


- 旨在发现**紧密相关**的观测值**组群**，使得与属于不同簇的观测值相比，属于**同一簇**的观测值之间**尽可能类似**模式
- 任务目标：**簇间距离最大化**和**簇内距离最小化**



4. 数据挖掘的任务

4. 推荐算法


- 通过一些数学算法，**推测**出用户可能**喜欢**的东西
- 任务目标：帮助用户**找到真正想要的**+**降低信息过载**



4. 数据挖掘的任务

5. 异常检测

- 识别特征显著不同于其他数据的观测值，这样的观测值称为**异常点**或**离群点**
- 任务目标：具有**高检测率**和**低误报率**






4. 数据挖掘的任务

6. 图数据分析

- 图(Graph) 是一个具有广泛含义的对象。
- 图被用来表示**实体与实体之间的关系**。这在生活中有着非常多的现实系统与之对应，比如化学分子、通信网络、社交网络等。


Serotonin $C_{10}H_{12}N_2O$




4. 数据挖掘的任务

6. 图数据分析


- 图数据分析任务包括：节点级别的任务、边级别的任务和图级别的任务。




节点级别



边级别



图级别



目 录

01

数据时代

02

数据挖掘概念

03

数据挖掘的起源

04

数据挖掘任务

05



数据挖掘要解决的问题

5. 数据挖掘要解决的问题

可伸缩性/可扩展性(Scalability)

■ 代表一种弹性，随着数据量的快速增长，能够保证旺盛的生命力，通过很少的改动甚至只是硬件设备的添置，就能实现处理能力的线性增长，实现高吞吐量和高性能


- 采样技术：随机采样，均匀采样，水库采样
- 并行(分布式)计算：Map/Reduce计算框架
- 在线/增量学习方法：持续学习 (Continual Learning)



5. 数据挖掘要解决的问题

高维性(High Dimensionality)

- 维度(Dimension)通常是指描述数据的属性或特征，比如地理位置、时间、类别、性别、职业等，它们是用来划分数据的类别或属性。
- 为低维数据开发的传统分析技术通常不能很好地处理高维数据。
- 某些分析算法，随着维度（特征数）的增加，计算复杂度会迅速增加。



5. 数据挖掘要解决的问题

异构和复杂(Heterogeneous and Complex)

- 传统分析方法只处理包含**相同类型(比如只有数值)**属性的数据集
- 现在的**数据类型更复杂**：文本、图像、音频和视频
- 为挖掘复杂对象，需要考虑**数据中的联系**
 - 时间和空间的自相关性
 - 图的连通性
 - 半结构化数据与XML文档的关系

指信号在1个时刻的瞬时值与另1个时刻的瞬时值之间的依赖关系

5. 数据挖掘要解决的问题

所有权和分布(Ownership and Distribution)

- 针对在物理上分布式存储的数据需要面临一些列挑战
 - 如何降低分布式计算所带来的额外通信开销
 - 如何有效地从多个数据源获得挖掘结果
 - 如何解决数据安全和隐私问题



讨论下列每项活动是否是数据挖掘任务：

- a) 一家电商公司的市场部门希望将客户分成几个不同的群体，以便为每个群体制定精准的营销策略。
- b) 某超市经理每天查看一份系统自动生成的报告，报告显示了昨天每个商品的销售额、总销售额以及与前天销售额的对比。
- c) 银行的风控系统实时监控着数百万张信用卡的交易流水。对于每一笔新发生的交易，系统会在毫秒级内判断其是否存在欺诈风险，并决定是否通过交易或联系持卡人确认。
- d) 公司财务使用软件，根据员工的考勤数据、绩效数据和既定的工资规则，计算出本月每位员工的应发工资。
- e) 航空公司在飞机引擎上安装了数百个传感器，持续收集温度、压力、振动频率等运行数据。它们希望利用这些数据，在引擎发生严重故障之前就预测出它可能出问题的时间，从而提前安排检修，避免航班延误和重大安全事故。